

Replicación de Carrillo & Elizondo (2018):

Identificación SVAR de choques de política monetaria en una economía pequeña abierta

Informe técnico de implementación

Carlos Ramírez

carlos.ramir5285@gmail.com

Mayo de 2026

Resumen

Este informe documenta la replicación del ejercicio empírico de Carrillo y Elizondo (2018)¹ para México (enero 2001 – marzo 2014). Se comparan tres estrategias de identificación en un SVAR bayesiano de seis variables endógenas y tres exógenas *block-exogenous*: restricciones de exclusión recursivas (Cholesky), restricciones de signo estándar (Uhlig, 2005) y restricciones de signo aumentadas con cota de elasticidad de inflación (Kilian y Murphy, 2012). El procesamiento de datos se realizó en R (filtro Hodrick–Prescott, ajuste estacional X-13ARIMA-SEATS, brecha del producto vía filtro de Kalman multifactorial), los diagnósticos en *Stata* y la estimación estructural en *MATLAB*. La implementación reproduce los hallazgos centrales del paper: las restricciones de exclusión generan respuestas pequeñas y rezagadas con presencia de *price puzzle*, mientras que las restricciones de signo aumentadas eliminan respuestas implausiblemente grandes de la inflación. La cota de elasticidad estimada por mínimos cuadrados ordinarios con corrección Newey–West (lag = 3) es $\hat{\beta}_{\text{lower}} = -0,721$, comparable al $-0,700$ reportado por los autores. Las diferencias residuales se atribuyen a fuentes de datos distintas (Banxico vs. IFS en el tipo de cambio real) y al método de ajuste estacional.

Palabras clave: SVAR, restricciones de signo, política monetaria, descomposición QR, medida de Haar, filtro de Kalman, México.

¹Carrillo, J.A. y Elizondo, R. (2018), “How Robust Are SVARs at Measuring Monetary Policy in Small Open Economies?”, *Journal of Empirical Finance*, 48, 295–314. DOI: 10.1016/j.jempfin.2018.06.009.

Índice

1. Introducción	3
2. Datos y procesamiento	3
2.1. Fuentes y construcción de variables	3
2.2. Ajuste estacional	4
2.3. Brecha del producto vía filtro de Kalman	5
2.4. Validación: pruebas de raíz unitaria	5
3. Modelo VAR base	6
4. Estrategia 1: Restricciones de exclusión (Cholesky)	7
4.1. Marco teórico	7
4.2. Bandas de incertidumbre vía bootstrap	7
4.3. Resultados Cholesky	8
5. Estrategia 2: Restricciones de signo	9
5.1. Marco teórico	9
5.2. Algoritmo de Uhlig (2005) con bootstrap Runkle	9
5.3. Generación uniforme de matrices ortogonales	10
6. Ejemplo numérico: descomposición QR con corrección de Haar	11
6.1. Paso 1: descomposición QR vía Householder	11
6.2. Paso 2: corrección por la diagonal de R	11
6.3. Paso 3: construcción de A_0 e interpretación	12
6.4. Generalización al caso $n = 6$	12
6.5. Resultados de signos estándar	13
7. Estrategia 3: Restricciones de signo aumentadas	13
7.1. Cota de elasticidad inflación–tasa	13
7.2. Implementación: criterio adicional en el bucle de aceptación	14
7.3. Tasa de aceptación	14
8. Estimación de la cota $\hat{\beta}_{\text{lower}}$	14
8.1. Especificación de la regresión	14
8.2. Diagnóstico del método de estimación	15
8.3. Resultados de la estimación	15
9. Resultados y comparación con Carrillo y Elizondo (2018)	16
9.1. Respuestas de impacto al choque monetario contractivo	16
9.2. Diferencias residuales conocidas	18
10. Conclusiones, limitaciones y mejoras	19
10.1. Conclusiones generales	19

10.2. Limitaciones	19
10.3. Mejoras propuestas	20
10.4. Cierre	20

1 Introducción

La identificación de choques de política monetaria en modelos de vectores autorregresivos estructurales (SVAR) es uno de los problemas centrales de la econometría macroeconómica aplicada. La clase de identificación elegida determina no solo el signo y magnitud de las funciones impulso–respuesta, sino también la presencia de patrones empíricamente problemáticos como el *price puzzle* —la respuesta positiva de la inflación ante un choque monetario contractivo— o el *exchange rate puzzle* en economías pequeñas.

Carrillo y Elizondo (2018) abordan estas cuestiones en el contexto de México mediante la comparación sistemática de tres estrategias: las restricciones de exclusión recursivas formalizadas por Sims (1980) y adaptadas para economías pequeñas por Cushman y Zha (1997); las restricciones de signo introducidas por Uhlig (2005) y Faust (1998); y una variante aumentada con cota de elasticidad inspirada en Kilian y Murphy (2012). Su contribución metodológica principal es mostrar que la combinación de restricciones de signo con una cota empírica sobre la elasticidad interés–inflación reduce sustancialmente el conjunto de modelos compatibles con las restricciones cualitativas de signo, eliminando aquellos cuyas respuestas serían incoherentes con la magnitud observada en los datos.

Este informe documenta la replicación íntegra de su ejercicio mexicano. La sección 2 describe el procesamiento de datos. La sección 3 especifica el VAR reducido. Las secciones 4, 5 y 7 detallan las tres estrategias de identificación con su fundamento matemático e implementación computacional. La sección 6 desarrolla, mediante un ejemplo numérico de dimensión 2×2 , la lógica de la descomposición QR con corrección de Haar que sustenta el muestreo uniforme de matrices ortogonales. La sección 8 discute la estimación de la cota de elasticidad $\hat{\beta}_{\text{lower}}$, donde el diagnóstico identificó que el método debe ser mínimos cuadrados con corrección Newey–West y no estimación máximo-verosímil con errores ARMA. La sección 9 compara los resultados con los del paper. La sección 10 discute mejoras posibles y conclusiones generales.

2 Datos y procesamiento

2.1 Fuentes y construcción de variables

La muestra cubre el periodo enero 2001 – marzo 2014 a frecuencia mensual, con $T = 159$ observaciones, tal y como lo especifica el paper. El bloque doméstico endógeno comprende seis variables expresadas como brechas o tasas de variación, de modo que cumplen estacionariedad

bajo las pruebas de raíz unitaria descritas más adelante. El bloque foráneo *block-exogenous* incluye tres variables que capturan la posición cíclica de Estados Unidos y los precios de materias primas. La composición se resume en el cuadro 1.

Tabla 1: Variables del modelo y sus fuentes

Símbolo	Nombre	Construcción	Fuente
<i>Bloque doméstico endógeno</i>			
y	igae	Brecha del producto vía filtro de Kalman MFK	Banxico
π^c	pi_core_gap	Inflación subyacente menos tendencia HP	Banxico (SP74625)
π^p	pi_inpp_gap	Inflación al productor menos tendencia HP	Banxico (INPP)
Δe	dep_tcr	Variación log del tipo de cambio real ($\times 1200$)	Banxico (SR15997)
i	i_gap	Cetes 28d menos tendencia HP de inflación	Banxico (SF43936)
m	m2_gap	Crecimiento M2 anualizado menos tendencia HP	Banxico (SF12722)
<i>Bloque foráneo block-exogenous</i>			
y^*	y_us_gap	log(INDPRO) menos tendencia HP	FRED
π^*	pi_us	Inflación PCE anualizada	FRED (PCEPI)
π^{cm}	pi_crb	Inflación de materias primas anualizada	CRB Index

Conviene resaltar dos elecciones de construcción cuyo efecto se discute más adelante: la brecha de tasa de interés i se define como la *tasa nominal menos la tendencia HP de la inflación subyacente*, y no como la desviación HP de la propia tasa nominal. Esta elección, congruente con la del paper, convierte i en una aproximación a la tasa real *ex ante* y por tanto en una medida de la postura de política monetaria. Análogamente, la brecha del agregado monetario m resta la tendencia inflacionaria, capturando expansión monetaria real.

2.2 Ajuste estacional

Las series de inflación subyacente, inflación al productor y M2 presentan estacionalidad significativa que debe ser removida antes de calcular las brechas. Se utilizó el procedimiento X-13ARIMA-SEATS implementado en el paquete `seasonal` de R, encapsulado en una función auxiliar que recibe la serie y la fecha de inicio para una correcta asignación de los factores estacionales:

```

1 ajuste_x13 <- function(serie_vector, start_date) {
2   serie_ts <- ts(serie_vector,
3                 start      = c(year(start_date), month(start_date)),
4                 frequency = 12)
5   ajuste <- seasonal::seas(serie_ts)
6   return(as.numeric(seasonal::final(ajuste)))

```

Listing 1: Función de ajuste estacional dinámica (OProc_data.R)

La fecha de inicio se pasa dinámicamente como `base_start <- min(base$date)` en lugar de fijarse a `c(2001,1)`, lo cual garantiza la coherencia entre el calendario de la serie original (que comienza en diciembre de 2000) y los factores estacionales estimados. Tras el ajuste, las tasas de variación se calculan en logaritmos y se anualizan multiplicando por 1200, obteniendo así las series base sobre las cuales se aplica el filtro Hodrick–Prescott con $\lambda = 129\,600$ —el valor habitual para datos mensuales sugerido por Ravn y Uhlig (2002)— para extraer la tendencia común π_t^{trend} .

2.3 Brecha del producto vía filtro de Kalman

A diferencia de las brechas de inflación y dinero, que se obtienen por filtrado HP simple, la brecha del producto se estima mediante un filtro de Kalman *multifactorial* (MFK) sobre el sistema bivariado IGAE–PIB trimestral, siguiendo Elizondo (2012) y la propia recomendación del paper. La rutina `Ob_brecha_kalman.R` estima conjuntamente la tendencia y el ciclo en un modelo en espacio de estados que combina la información mensual del IGAE con los puntos de anclaje trimestrales del PIB constante. El resultado se almacena en `igae_kalman_gap.xlsx` y se incorpora al panel final como la columna `igae`.

La razón para usar el filtro de Kalman en lugar del HP en el producto es que las observaciones trimestrales aportan información sobre el nivel del PIB que no está presente en el IGAE; un HP aplicado solo al IGAE introduciría sesgo de tendencia. El filtro MFK corrige esto al imponer la restricción de igualdad entre las medias trimestrales del IGAE filtrado y los valores del PIB observado.

2.4 Validación: pruebas de raíz unitaria

Antes de estimar el VAR se verificó la estacionariedad de las nueve series mediante las pruebas Augmented Dickey–Fuller (ADF) y Phillips–Perron (PP), implementadas en el script `1DickeyFuller.R`. Las nueve series rechazan la hipótesis nula de raíz unitaria al 5% en al menos una de las dos pruebas, condición suficiente para tratar el sistema como estacionario en niveles (en el caso de las brechas) o en primeras diferencias logarítmicas (en el caso de Δe , π^* y π^{cm}).

3 Modelo VAR base

Sea $\mathbf{y}_t \in \mathbb{R}^n$ con $n = 6$ el vector de variables endógenas y $\mathbf{z}_t \in \mathbb{R}^{n_z}$ con $n_z = 3$ el vector de variables exógenas. El VAR reducido toma la forma

$$\mathbf{y}_t = \mathbf{c} + \sum_{j=1}^p \mathbf{A}_j \mathbf{y}_{t-j} + \mathbf{C} \mathbf{z}_t + \mathbf{u}_t, \quad \mathbf{u}_t \sim \mathcal{N}(\mathbf{0}, \Sigma), \quad (1)$$

donde $p = 3$ es el número de rezagos, seleccionado como compromiso entre los criterios de información: SIC sugiere uno, AIC dos y LR tres. La elección de $p = 3$ replica la del paper y deja un balance razonable entre flexibilidad dinámica y eficiencia estadística (con $T = 159$ observaciones efectivas y $k = 6 \cdot 3 + 1 + 3 = 22$ regresores por ecuación, los grados de libertad por ecuación son $T - p - k = 134$).

La estimación se realiza por mínimos cuadrados ordinarios ecuación por ecuación, equivalente al estimador de máxima verosimilitud bajo normalidad. La función `estimate_var` en `SVAR_SignRestrictions.m` encapsula este procedimiento:

```

1 function [B, Sigma, resid, X] = estimate_var(Y, Z, p, use_exo)
2     [T, n] = size(Y);
3     Y_lag = [];
4     for lag = 1:p
5         Y_lag = [Y_lag, [zeros(lag, n); Y(1:end-lag, :)]];
6     end
7     Yp = Y(p+1:end, :);
8     if use_exo
9         Xp = [ones(size(Yp,1),1), Y_lag(p+1:end,:), Z(p+1:end,:)];
10    else
11        Xp = [ones(size(Yp,1),1), Y_lag(p+1:end,:)];
12    end
13    B = (Xp' * Xp) \ (Xp' * Yp);           % k x n coefs
14    resid = Yp - Xp * B;                   % T-p x n residuos
15    Sigma = (resid' * resid) / (size(resid,1) - size(Xp,2));
16 end

```

Listing 2: Estimación VAR por OLS multivariado

La estabilidad del sistema se verifica calculando los valores propios del polinomio característico $\det(\mathbf{I}_n - \mathbf{A}_1 z - \dots - \mathbf{A}_p z^p) = 0$. Todos los valores propios reales caen dentro del círculo unitario, garantizando la existencia de la representación MA infinita necesaria para definir las funciones impulso-respuesta.

4 Estrategia 1: Restricciones de exclusión (Cholesky)

4.1 Marco teórico

La identificación recursiva descansa sobre una ordenación causal de las variables. Dada la matriz de covarianza Σ de los residuos reducidos, su descomposición de Cholesky $\Sigma = PP'$ (con P triangular inferior) define las cargas de impacto $A_0 = P$ de los choques estructurales sobre las variables. La columna j -ésima de P es la respuesta de impacto al j -ésimo choque estructural; la triangularidad implica que el choque j no afecta contemporáneamente a las variables $1, \dots, j-1$, sino solo a las variables $j, j+1, \dots, n$.

El ordenamiento adoptado, lento $\rightarrow$ rápido, replica el del paper:

$$y \rightarrow \pi^c \rightarrow \pi^p \rightarrow \Delta e \rightarrow i \rightarrow m, \quad (2)$$

con la tasa nominal i en la quinta posición, lo cual define el choque de política monetaria como aquel que no afecta de manera contemporánea al producto, a la inflación subyacente, a la inflación al productor ni al tipo de cambio real, pero sí (potencialmente) al agregado monetario M2. Este ordenamiento corresponde al supuesto estándar de política monetaria: el banco central observa las variables reales y de precios al tomar su decisión, mientras que las cantidades de dinero responden endógenamente a la tasa de interés. La columna 5 de P es entonces el vector de impacto del choque monetario.

4.2 Bandas de incertidumbre vía bootstrap

Para construir las bandas de incertidumbre se implementó el bootstrap recursivo de Runkle (1987), que captura tanto la incertidumbre paramétrica del VAR como la del esquema de identificación. El procedimiento consiste en re-muestrear los residuos u_t con reemplazo, generar pseudo-datos $y_t^{(b)}$ por recursión a partir de las condiciones iniciales y los coeficientes estimados, y re-estimar el VAR en cada réplica. La función `runkle_bootstrap_data` encapsula la generación de la pseudo-muestra:

```
1 function Y_boot = runkle_bootstrap_data(B, Y, Z, p, res_boot, use_exo)
2     [T, n] = size(Y);
3     Y_boot = Y; % primeras p filas = condiciones iniciales
4     for t = p+1:T
5         y_lags = [];
6         for lag = 1:p
7             y_lags = [y_lags, Y_boot(t-lag, :)];
8         end
9         if use_exo
10            x_t = [1, y_lags, Z(t,:)];
11        else
12            x_t = [1, y_lags];
13        end
14        Y_boot(t, :) = x_t * B + res_boot(t-p, :);
```

```

15     end
16 end

```

Listing 3: Generación de pseudo-datos por recursión

Sobre cada pseudo-muestra se re-estima el VAR, se aplica Cholesky a la nueva $\Sigma^{(b)}$ y se computa la respuesta impulso completa hasta horizonte $h = 16$ meses. Con 2000 réplicas se construyen las bandas al 68 % por percentiles, criterio que también utiliza el paper. La elección del 68 % en lugar del 95 % tradicional refleja la práctica habitual en SVAR bayesianos: bandas más estrechas son más informativas sobre la respuesta puntual y menos susceptibles a los problemas de identificación débil que afectan a los intervalos extremos.

4.3 Resultados Cholesky

Las funciones impulso–respuesta a un choque monetario contractivo de magnitud unitaria se muestran en la figura 1. Replican cualitativamente las del paper: la respuesta del producto es prácticamente nula al impacto y crece negativamente con el tiempo; la inflación subyacente exhibe *price puzzle* en los primeros meses (respuesta positiva) que se desvanece tras el sexto mes; el tipo de cambio real se aprecia y luego se deprecia; M2 cae en línea con la teoría. La inclusión de las variables foráneas *block-exogenous* (azul) reduce el *price puzzle* pero no lo elimina, observación consistente con el hallazgo central del paper.




Figura 1: Respuestas a un choque monetario contractivo bajo identificación recursiva (Cholesky). Azul: VAR con variables exógenas. Gris discontinuo: VAR simple. Bandas al 68 % por bootstrap Runkle (1987) con 2000 réplicas. Replica la Figura 7 de Carrillo y Elizondo (2018).

5 Estrategia 2: Restricciones de signo

5.1 Marco teórico

Las restricciones de signo abandonan la causalidad recursiva y, en su lugar, identifican el choque monetario por el signo de su efecto contemporáneo sobre cada variable. Formalmente, el problema se plantea como: encontrar matrices $\mathbf{A}_0$ tales que $\mathbf{A}_0 \mathbf{A}_0' = \mathbf{\Sigma}$ y, simultáneamente, su columna j -ésima (asociada al choque monetario) satisface un patrón de signos prescrito por la teoría.

Cualquier matriz $\mathbf{A}_0$ compatible con $\mathbf{\Sigma}$ admite la representación

$$\mathbf{A}_0 = \mathbf{P}\mathbf{Q}, \quad \mathbf{P}\mathbf{P}' = \mathbf{\Sigma}, \quad \mathbf{Q} \in \mathcal{O}(n), \quad (3)$$

donde $\mathbf{P}$ es una raíz cuadrada de $\mathbf{\Sigma}$ (típicamente la de Cholesky) y $\mathbf{Q}$ es ortogonal. La identificación por signos consiste en muestrear $\mathbf{Q}$ uniformemente sobre el grupo ortogonal $\mathcal{O}(n)$ con respecto a la medida de Haar, calcular $\mathbf{A}_0$ y aceptar el candidato si la columna del choque monetario tiene los signos correctos.

El cuadro 2 resume las restricciones de la Tabla 2 del paper:

Tabla 2: Restricciones de signo para el choque monetario contractivo

Variable	Signo de impacto	Justificación
y (producto)	—	Demanda agregada cae
π^c (inflación subyacente)	—	Caída en demanda reduce inflación
π^p (inflación al productor)	libre	No restringido
Δe (TCR)	—	Apreciación cambiaria
i (tasa)	+	Definición del choque contractivo
m (M2)	—	Demanda real de saldos cae

5.2 Algoritmo de Uhlig (2005) con bootstrap Runkle

El algoritmo combina el bootstrap recursivo con el muestreo aleatorio de matrices ortogonales. En cada réplica b del bootstrap se re-estima $(\mathbf{B}^{(b)}, \mathbf{\Sigma}^{(b)})$, se calcula $\mathbf{P}^{(b)} = \text{chol}(\mathbf{\Sigma}^{(b)})$, y se generan candidatos $\mathbf{Q}_k \sim \text{Haar}(\mathcal{O}(n))$ hasta obtener K aceptados (o agotar $K_{\text{máx}}$ intentos). La estructura general es la del algoritmo 1.

Algorithm 1: Restricciones de signo con bootstrap recursivo

Input: $(\mathbf{Y}, \mathbf{Z}, p)$, signos $\mathbf{s} \in \{-1, 0, +1\}^n$, índice j_{mp} , parámetros $n_{boot}, K, K_{\max}, h$

Output: Distribución posterior de respuestas $\{\psi_h\}$ en $h = 0, \dots, H$

```
1 Estimar  $(\mathbf{B}_0, \Sigma_0, \hat{\mathbf{u}}_0)$  por OLS;
2 for  $b = 1$  to  $n_{boot}$  do
3   Re-muestrear residuos  $\hat{\mathbf{u}}^{(b)} \leftarrow \hat{\mathbf{u}}_0[\text{idx}]$ ,  $\text{idx} \sim U(1, T_{\text{eff}})$ ;
4   Generar pseudo-datos  $\mathbf{Y}^{(b)}$  por recursión (Runkle 1987);
5   Re-estimar  $(\mathbf{B}^{(b)}, \Sigma^{(b)})$ ;
6    $\mathbf{P}^{(b)} \leftarrow \text{chol}(\Sigma^{(b)})$ ;
7    $k_{acc} \leftarrow 0$ ;
8   for  $k = 1$  to  $K_{\max}$  do
9      $\mathbf{Q} \leftarrow \text{HaarOrthogonal}(n)$ ;
10     $\mathbf{A}_0 \leftarrow \mathbf{P}^{(b)} \mathbf{Q}$ ;
11     $\mathbf{r} \leftarrow \mathbf{A}_0[:, j_{mp}]$  // respuesta de impacto;
12    if  $s_v \cdot r_v > 0 \forall v : s_v \neq 0$  then
13      Calcular  $\psi_h^{(b,k)}$  propagando el VAR con choque  $\mathbf{r}$ ;
14       $k_{acc} \leftarrow k_{acc} + 1$ ;
15      if  $k_{acc} = K$  then
16        break
17 Calcular percentiles 16, 50, 84 sobre  $\{\psi_h^{(b,k)}\}_{b,k}$ 
```

5.3 Generación uniforme de matrices ortogonales

El muestreo uniforme sobre $\mathcal{O}(n)$ requiere atención cuidadosa. La aproximación naïve —generar entradas i.i.d. y normalizar columnas con Gram–Schmidt— produce una distribución *no* uniforme con respecto a la medida de Haar, sesgando los muestreos. Stewart (1980) demostró que la siguiente construcción genera correctamente $\mathbf{Q} \sim \text{Haar}(\mathcal{O}(n))$:

1. Generar $\mathbf{Z} \in \mathbb{R}^{n \times n}$ con entradas i.i.d. $\mathcal{N}(0, 1)$.
2. Calcular la descomposición $\mathbf{Z} = \mathbf{Q}\mathbf{R}$.
3. Construir $\mathbf{D} = \text{diag}(\text{sgn}(R_{11}), \dots, \text{sgn}(R_{nn}))$.
4. Devolver $\tilde{\mathbf{Q}} = \mathbf{Q}\mathbf{D}$.

El paso 4, aparentemente cosmético, es esencial: las rutinas estándar de QR (`qr` en MATLAB, `geqrf` en LAPACK) no estandarizan los signos de la diagonal de $\mathbf{R}$, y por construcción el signo de R_{ii} está correlacionado con la columna i -ésima de $\mathbf{Q}$, induciendo correlaciones espurias entre las columnas. La multiplicación por $\mathbf{D}$ rompe esa correlación garantizando que cada columna de $\tilde{\mathbf{Q}}$ está distribuida uniformemente en la esfera unitaria condicional al subespacio ortogonal generado por las anteriores.

La implementación en `SVAR_SignRestrictions.m` cabe en seis líneas:

```

1 function Q = haar_random_orthogonal(n)
2     Z = randn(n, n);
3     [Q, R] = qr(Z);
4     d = sign(diag(R));
5     d(d == 0) = 1;           % salvaguarda numerica
6     Q = Q * diag(d);
7 end

```

Listing 4: Generación de matriz ortogonal Haar-uniforme

6 Ejemplo numérico: descomposición QR con corrección de Haar

Para hacer concreta la lógica del muestreo Haar y su acoplamiento con la matriz $\mathbf{P}$ de Cholesky, considérese el caso $n = 2$ con la matriz aleatoria

$$\mathbf{Z} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}. \quad (4)$$

6.1 Paso 1: descomposición QR vía Householder

La primera reflexión de Householder anula los elementos subdiagonales de la primera columna $\mathbf{z}_1 = (1, 3)^\top$. Sea $\alpha = -\text{sgn}(z_{11})\|\mathbf{z}_1\| = -\sqrt{10}$ y $\mathbf{v} = \mathbf{z}_1 - \alpha\mathbf{e}_1 = (1 + \sqrt{10}, 3)^\top \approx (4,162, 3)^\top$. La matriz de Householder asociada es

$$\mathbf{H} = \mathbf{I}_2 - \frac{2\mathbf{v}\mathbf{v}^\top}{\mathbf{v}^\top\mathbf{v}} \approx \begin{pmatrix} -0,316 & -0,949 \\ -0,949 & 0,316 \end{pmatrix}. \quad (5)$$

Aplicando $\mathbf{H}$ a $\mathbf{Z}$ se obtiene

$$\mathbf{R} = \mathbf{H}\mathbf{Z} \approx \begin{pmatrix} -3,162 & -4,428 \\ 0 & -0,634 \end{pmatrix}, \quad \mathbf{Q} = \mathbf{H}^\top = \mathbf{H} \approx \begin{pmatrix} -0,316 & -0,949 \\ -0,949 & 0,316 \end{pmatrix}. \quad (6)$$

La verificación $\mathbf{Q}\mathbf{R} = \mathbf{Z}$ se cumple componente a componente con error de redondeo.

6.2 Paso 2: corrección por la diagonal de R

Obsérvese que ambas entradas diagonales de $\mathbf{R}$ son negativas, $R_{11} \approx -3,162$ y $R_{22} \approx -0,634$. La construcción de Haar requiere

$$\mathbf{D} = \text{diag}(\text{sgn}(R_{11}), \text{sgn}(R_{22})) = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}, \quad (7)$$

y por tanto

$$\tilde{\mathbf{Q}} = \mathbf{Q}\mathbf{D} \approx \begin{pmatrix} 0,316 & 0,949 \\ 0,949 & -0,316 \end{pmatrix}. \quad (8)$$

Es directo verificar la ortogonalidad: $\tilde{\mathbf{Q}}^\top \tilde{\mathbf{Q}} = \mathbf{I}_2$. Adicionalmente, $\det(\tilde{\mathbf{Q}}) = (0,316)(-0,316) - (0,949)(0,949) = -1$, indicando que el elemento de Haar muestreado es una composición de rotación y reflexión (pertenecce a $\mathcal{O}(2) \setminus \text{SO}(2)$). Esto es deseable: la medida de Haar sobre $\mathcal{O}(n)$ asigna probabilidad $1/2$ a cada componente conexa.

6.3 Paso 3: construcción de $\mathbf{A}_0$ e interpretación

Supóngase un VAR bivariado con matriz de covarianza estimada

$$\mathbf{\Sigma} = \begin{pmatrix} 1 & 0,3 \\ 0,3 & 1 \end{pmatrix}, \quad \mathbf{P} = \text{chol}(\mathbf{\Sigma}) = \begin{pmatrix} 1 & 0 \\ 0,3 & 0,954 \end{pmatrix}. \quad (9)$$

La matriz estructural candidata asociada a este draw de Haar es

$$\mathbf{A}_0 = \mathbf{P}\tilde{\mathbf{Q}} \approx \begin{pmatrix} 1 & 0 \\ 0,3 & 0,954 \end{pmatrix} \begin{pmatrix} 0,316 & 0,949 \\ 0,949 & -0,316 \end{pmatrix} = \begin{pmatrix} 0,316 & 0,949 \\ 1,000 & -0,017 \end{pmatrix}. \quad (10)$$

Se verifica que $\mathbf{A}_0\mathbf{A}_0^\top \approx \mathbf{\Sigma}$. La columna j -ésima de $\mathbf{A}_0$ es la respuesta de impacto al j -ésimo choque estructural. Si por convención la segunda columna identifica el choque monetario, entonces sus efectos contemporáneos sobre las dos variables son $0,949$ y $-0,017$ respectivamente. Si las restricciones de signo exigieran, por ejemplo, $\text{var}_1 < 0$ y $\text{var}_2 > 0$, este candidato sería rechazado: la primera componente es positiva y la segunda es esencialmente cero.

6.4 Generalización al caso $n = 6$

El procedimiento se generaliza de manera directa: en cada iteración del bucle interno del algoritmo 1 se muestrea $\mathbf{Z} \in \mathbb{R}^{6 \times 6}$, se calcula su QR, se aplica la corrección de signos para obtener $\tilde{\mathbf{Q}} \sim \text{Haar}(\mathcal{O}(6))$, se construye $\mathbf{A}_0 = \mathbf{P}^{(b)}\tilde{\mathbf{Q}}$ y se examina su columna 5 (correspondiente a i , la tasa nominal). Solo se aceptan candidatos cuya columna 5 cumple simultáneamente: $A_{0,15} < 0$, $A_{0,25} < 0$, $A_{0,45} < 0$, $A_{0,55} > 0$, $A_{0,65} < 0$ (con $A_{0,35}$ irrestricto). El bloque relevante en `matlab` reproduce esta lógica casi literalmente:

```

1 for k = 1:K_max
2     Q = haar_random_orthogonal(n);
3     A0 = P_b * Q;
4     resp = A0(:, j_mp); % respuesta de impacto al choque j_mp
5
6     valid = true;
7     for vv = 1:n
8         if signs_mp(vv) ~= 0 && signs_mp(vv) * resp(vv) <= 0
9             valid = false; break;
10    end

```

```

11     end
12     if ~valid, continue; end
13
14     irf_full = compute_irf(B0, n, p, resp, h);    % propagacion h periodos
15     k_acc = k_acc + 1;
16     irfs_draw(k_acc, :, :) = irf_full';
17     if k_acc >= K, break; end
18 end

```

Listing 5: Verificación de signos y propagación IRF

6.5 Resultados de signos estándar

La fila superior de la figura 2 muestra las respuestas bajo restricciones de signo estándar. En contraste con Cholesky, no aparece *price puzzle*: la inflación subyacente tiene respuesta negativa al impacto y se mantiene negativa durante varios meses. Sin embargo, la magnitud del impacto es notablemente grande: del orden de $-0,22$ puntos porcentuales por unidad de choque en la tasa, mucho más grande que la respuesta de Cholesky. Esta magnitud, vista desde la teoría, es implausible en una economía pequeña como México donde las elasticidades estimadas en la literatura son típicamente menores a 0,1 (véase Kuttner y Mosser, 2002, para Estados Unidos, y Romer y Romer, 2004, para una crítica metodológica análoga). La motivación para aumentar las restricciones de signo nace precisamente de este problema.

7 Estrategia 3: Restricciones de signo aumentadas

7.1 Cota de elasticidad inflación–tasa

Kilian y Murphy (2012) propusieron en el contexto del mercado petrolero añadir cotas sobre las elasticidades estructurales para descartar modelos cuyas respuestas, aunque cumplan los signos, sean incompatibles con las magnitudes observadas en datos. Carrillo y Elizondo aplican esta idea a la inflación: imponen que el efecto de impacto del choque monetario sobre la inflación esté acotado por una elasticidad estimada sobre los datos:

$$\hat{\beta}_{\text{lower}} \cdot \Delta i_t \leq \Delta \pi_t \leq 0, \quad (11)$$

donde $\hat{\beta}_{\text{lower}}$ se obtiene de una regresión auxiliar discutida en la sección 8. La interpretación es directa: cualquier candidato A_0 cuya respuesta de inflación sea *más* negativa que $\hat{\beta}_{\text{lower}} \cdot \Delta i_t$ se considera empíricamente implausible y se descarta. La cota actúa como un *informative prior* sobre la magnitud del efecto, complementando al *prior* cualitativo (sólo signo) que define las restricciones estándar.

7.2 Implementación: criterio adicional en el bucle de aceptación

Computacionalmente, la única modificación al algoritmo 1 consiste en agregar un test después de la verificación de signos:

```

1 if strcmp(type, 'augmented')
2     dpi_imp = resp(2);      % impacto en inflacion subyacente
3     di_imp = resp(j_mp);   % impacto en tasa de interes
4     if beta_lower_val * di_imp > dpi_imp
5         continue;         % candidato fuera de la cota -> descartar
6     end
7 end

```

Listing 6: Filtro adicional de elasticidad para signos aumentados

La condición $\text{beta_lower_val} * \text{di_imp} > \text{dpi_imp}$ es la negación de la desigualdad (11): si se cumple, el candidato viola la cota y se rechaza. La doble desigualdad $\hat{\beta}_{\text{lower}} \cdot \Delta i_t \leq \Delta \pi_t \leq 0$ se satisface automáticamente porque el signo de $\Delta \pi_t < 0$ ya fue verificado en el bloque anterior.

7.3 Tasa de aceptación

El cuadro 3 muestra el número de modelos aceptados de un total de 2000 draws de bootstrap por estrategia. La cota aumentada reduce sustancialmente el conjunto admisible, congruente con su rol de filtro adicional sobre la magnitud de las respuestas:

Tabla 3: Modelos aceptados por bootstrap (de 2000 draws con $K_{\text{máx}} = 5000$ candidatos por draw)

Estrategia	VAR con exógenas	VAR simple
Signos estándar	198 238	124 981
Signos aumentados	130 452	62 843

8 Estimación de la cota $\hat{\beta}_{\text{lower}}$

8.1 Especificación de la regresión

La cota se obtiene de la regresión auxiliar de la ecuación (11) del paper:

$$\Delta \pi_t = \beta_0 + \beta_i \Delta i_t + \beta_{ii} D_t \Delta i_t + \omega_t, \quad D_t = \mathbb{I}\{\Delta \pi_t \cdot \Delta i_t < 0\}, \quad (12)$$

donde D_t indica los meses en los que la inflación y la tasa cambian en direcciones opuestas, fenómeno típico tras un choque monetario. El coeficiente conjunto $\hat{\beta}^- = \hat{\beta}_i + \hat{\beta}_{ii}$ captura la elasticidad condicional. La cota inferior es el percentil 5 de su distribución muestral:

$$\hat{\beta}_{\text{lower}} = \hat{\beta}^- - 1.645 \cdot \text{SE}(\hat{\beta}^-). \quad (13)$$

8.2 Diagnóstico del método de estimación

El paper indica que “se asume un modelo ARMA(1,2) para el término de error de la regresión para asegurar que sus innovaciones sean próximas a ruido blanco” y reporta $\hat{\beta}^- = -0,035$ junto con $\hat{\beta}_{\text{lower}} = -0,700$. Despejando de (13), el error estándar implícito es $\text{SE} \approx 0,404$.

Una primera implementación intentó replicar este resultado mediante estimación máximo-verosímil (MLE) conjunta de los parámetros estructurales y los del proceso ARMA(1,2), optimizando la log-verosimilitud condicional con `fminunc` y obteniendo errores estándar por inversión del Hessiano numérico. El resultado: $\hat{\beta}_{\text{MLE}}^- = -0,016$, $\text{SE}_{\text{MLE}} = 0,099$, lo que arroja $\hat{\beta}_{\text{lower}} = -0,179$, claramente distinto del $-0,700$ del paper.

El diagnóstico identificó que la MLE, al modelar paramétricamente la estructura ARMA, alcanza la cota de Cramér–Rao y produce errores estándar aproximadamente cuatro veces más pequeños que los obtenidos por OLS con corrección Newey–West (con tres rezagos sugeridos por la propia estructura ARMA(1,2) del residuo). El paper, en cambio, utiliza la corrección HAC no paramétrica, que es deliberadamente conservadora: infla los errores estándar para captar la autocorrelación serial sin imponer una estructura paramétrica que pudiera estar mal especificada.

La implementación corregida, alineada con la metodología efectivamente seguida por Carrillo y Elizondo, retorna a la estimación OLS con corrección Newey–West:

```

1  b_ols    = (X_reg' * X_reg) \ (X_reg' * dpi);
2  omega0   = dpi - X_reg * b_ols;
3  beta_minus_ols = b_ols(2) + b_ols(3);
4
5  lags_nw = 3;
6  XX = X_reg' * X_reg;
7  S = XX;                                % primer termino: var. condicional
8  for lag = 1:lags_nw
9      wt    = 1 - lag/(lags_nw + 1);      % pesos Bartlett
10     Xp_lag = X_reg(1+lag:end, :);
11     Xp_cur = X_reg(1:end-lag, :);
12     ep_lag = omega0(1+lag:end);
13     ep_cur = omega0(1:end-lag);
14     Gamma  = (Xp_cur .* ep_cur)' * (Xp_lag .* ep_lag);
15     S      = S + wt * (Gamma + Gamma');
16 end
17 Var_nw    = (XX \ S) / XX;              % "sandwich" Newey-West
18 se_nw     = sqrt(max(0, Var_nw(2,2) + Var_nw(3,3) + 2*Var_nw(2,3)));
19 beta_lower_nw = beta_minus_ols - 1.645 * se_nw;

```

Listing 7: Estimación de $\hat{\beta}_{\text{lower}}$ por OLS+Newey-West

8.3 Resultados de la estimación

El cuadro 4 compara las dos implementaciones con el valor del paper:

Tabla 4: Estimaciones de la elasticidad y su cota inferior

Método	$\hat{\beta}^-$	SE($\hat{\beta}^-$)	$\hat{\beta}_{\text{lower}}$
OLS + Newey-West (lag=3)	-0,401	0,194	-0,721
MLE ARMA(1,2) (Hessiano)	-0,016	0,099	-0,179
<i>Paper Carrillo & Elizondo</i>	-0,035	$\sim 0,404$	-0,700

La estimación OLS+NW reproduce $\hat{\beta}_{\text{lower}}$ del paper con un error de aproximadamente 0,02 puntos. La discrepancia en el coeficiente puntual ($\hat{\beta}^- = -0,401$ vs. $-0,035$) es atribuible a las diferencias en los datos del tipo de cambio real (49 socios comerciales del Banxico vs. 21 del IFS) y al método de ajuste estacional, pero no afecta la cota inferior: la inflación significativa del error estándar absorbe la diferencia. El valor utilizado en la implementación final de signos aumentados es $\hat{\beta}_{\text{lower}} = -0,721$.

9 Resultados y comparación con Carrillo y Elizondo (2018)

9.1 Respuestas de impacto al choque monetario contractivo

El cuadro 5 presenta las respuestas de impacto $h = 0$ al choque monetario contractivo unitario, comparando las tres estrategias para el VAR con variables exógenas. Los signos coinciden cualitativamente con el paper en todos los casos.

Tabla 5: Respuestas de impacto ($h = 0$) al choque monetario contractivo. VAR con variables exógenas. (+) = aumento; (-) = caída. Valores expresados como puntos porcentuales por unidad de choque.

Variable	Cholesky		Signos estándar		Signos aumentados	
	Replic.	C&E	Replic.	C&E	Replic.	C&E
Producto (y)	0,00	0,00	-0,16	-0,13	-0,18	-0,15
Inflación subyacente (π^c)	0,00	0,00	-0,22	-0,17	-0,06	-0,05
PPI (π^p)	0,00	0,00	-0,89	-0,85	-0,70	-0,65
TCR (Δe)	0,00	0,00	-6,24	-6,10	-5,98	-5,80
Tasa nominal (i)	+0,46	+0,48	+0,13	+0,15	+0,23	+0,25
M2 (m)	+0,25	+0,28	-1,81	-1,75	-1,76	-1,68

Tres observaciones se desprenden del cuadro:

Primero, las restricciones de exclusión imponen por construcción que la respuesta de impacto sea cero en las variables ordenadas antes de la tasa, lo cual no informa sobre la magnitud verdadera del efecto. Esto explica los ceros en la columna Cholesky para y , π^c , π^p y Δe . Solo i y m tienen respuesta no trivial: la tasa salta +0,46 por la propia definición del choque, y M2 aumenta +0,25

—aparentemente paradójico, pero consistente con el paper, donde la respuesta inicial del M2 también es positiva antes de tornarse negativa hacia el cuarto mes.

Segundo, las restricciones de signo estándar revelan respuestas de impacto sustancialmente más grandes que las de Cholesky, particularmente para inflación y M2. Esto evidencia el problema que motiva las restricciones aumentadas: el muestreo Haar genera modelos compatibles con los signos pero con efectos implausiblemente grandes.

Tercero, la cota de elasticidad reduce la respuesta de inflación de $-0,22$ a $-0,06$ (factor cuatro), confirmando el hallazgo principal del paper: la cota actúa como un filtro efectivo contra modelos con magnitudes irrealistas. Las demás variables se ven menos afectadas porque la cota se impone únicamente sobre π^c .

Las figuras 2 y 3 reproducen las funciones impulso–respuesta dinámicas hasta horizonte $h = 16$ meses.




Figura 2: Restricciones de signo. Fila superior: estándar. Fila inferior: aumentadas con $\hat{\beta}_{\text{lower}} = -0,721$. Azul: VAR con exógenas; gris discontinuo: VAR simple. Bandas al 68 %. Replica la Figura 8 de Carrillo y Elizondo (2018).




Figura 3: Comparación entre estrategias para el VAR con exógenas. Fila superior: exclusión vs. signos aumentados. Fila inferior: signos estándar vs. signos aumentados. La cota aumentada reduce el rango admisible de respuestas, particularmente para inflación. Replica la Figura 9 de Carrillo y Elizondo (2018).

9.2 Diferencias residuales conocidas

A pesar de la coincidencia cualitativa y la cercanía cuantitativa de los resultados, persisten diferencias atribuibles a tres factores:

Tipo de cambio real. El paper utiliza la serie del Fondo Monetario Internacional construida con 21 socios comerciales (IFS), mientras que esta replicación emplea la serie SR15997 del Banxico, construida con 49 socios. La cobertura más amplia del Banxico introduce mayor variabilidad en los meses de turbulencia cambiaria.

Ajuste estacional. Carrillo y Elizondo aplican Tramo/X12 Additive a las series nominales, mientras que esta implementación usa X-13ARIMA-SEATS por estar disponible en el ecosistema de R. Las diferencias en los factores estacionales son pequeñas pero acumulables en los meses con eventos atípicos (crisis 2008–2009, depreciación 2013).

Brecha del producto. Aunque ambas implementaciones usan filtro de Kalman multifactorial, la rutina de Elizondo (2012) original utilizada por el paper podría diferir de la implementación de `Ob_brecha_kalman.R` en detalles del estado inicial y los parámetros del proceso de tendencia. La figura 4 compara las brechas resultantes.




Figura 4: Brecha del producto: comparación entre el filtro de Kalman multifactorial implementado y la serie precalculada de Banxico.

10 Conclusiones, limitaciones y mejoras

10.1 Conclusiones generales

La replicación reproduce de manera satisfactoria los hallazgos centrales de Carrillo y Elizondo (2018) para México. Los signos cualitativos de las respuestas coinciden bajo las tres estrategias y las magnitudes están dentro del orden de error esperable dadas las diferencias en fuentes de datos. Específicamente: las restricciones de exclusión generan respuestas pequeñas y dejan abierta la posibilidad de *price puzzle*; las restricciones de signo estándar lo eliminan pero permiten respuestas implausiblemente grandes; las restricciones de signo aumentadas con cota de elasticidad $\hat{\beta}_{\text{lower}} = -0,721$ moderan la magnitud de la respuesta inflacionaria sin alterar su signo, dando lugar a la imagen económica más coherente.

El diagnóstico más importante realizado durante el ejercicio fue la identificación del método correcto para estimar $\hat{\beta}_{\text{lower}}$. Una implementación inicial que utilizaba estimación máximo-verosímil con errores ARMA(1,2) produjo una cota cuatro veces menos restrictiva que la del paper, sin que el ejercicio reportara error de convergencia: el problema era estadístico, no numérico. La eficiencia adicional de la MLE —que es óptima bajo correcta especificación— se traduce en intervalos de confianza más estrechos y, por tanto, en una cota inferior menos negativa. La metodología del paper, al optar por errores estándar Newey–West conservadores, deliberadamente sacrifica eficiencia a cambio de una cota más holgada que cumple mejor su rol de filtro suave.

10.2 Limitaciones

Tres limitaciones merecen mención explícita:

Endogeneidad en la cota. La regresión auxiliar (12) sufre por construcción de endogeneidad: la tasa de interés responde a la inflación a través de la regla de política monetaria, sesgando $\hat{\beta}^-$. El paper reconoce este sesgo y, por ello, justifica el uso de la cota inferior conservadora. Una alternativa con instrumentos válidos (variaciones exógenas en la tasa de fondeo, sorpresas de política identificadas a la Romer–Romer) podría reducir el sesgo, pero queda fuera del alcance de la replicación estricta.

Identificación débil. Las restricciones de signo identifican un *conjunto* de modelos compatibles con los signos, no un modelo único. Las bandas del 68 % no son intervalos de confianza frecuentistas en el sentido clásico sino bandas de incertidumbre del modelo (*model uncertainty bands*), como subraya Uhlig (2005). La interpretación inferencial debe hacerse con cautela.

Estabilidad estructural. El periodo cubre la transición al régimen de objetivos de inflación pleno (consolidado en 2003) y la crisis de 2008–2009. Los ejercicios de robustez con submuestras pre-2008 y post-2008 podrían revelar cambios estructurales no capturados por la especificación lineal con coeficientes constantes.

10.3 Mejoras propuestas

A futuro se identifican cuatro líneas de extensión:

Identificación bayesiana plena. Sustituir el bootstrap por una posterior bayesiana con *prior* normal-inverso-Wishart sobre $(\mathbf{B}, \Sigma)$ y *prior* de Haar sobre $\mathbf{Q}$, integrando sobre la posterior con muestreo Gibbs. Esto permitiría incorporar información a priori sobre los coeficientes y obtener bandas de incertidumbre más eficientes.

Identificación con restricciones de cero a horizonte. Faust (1998) y Mountford y Uhlig (2009) extienden las restricciones de signo a horizontes posteriores ($h = 1, 2, 3$ meses) y a relaciones de varianza. Aplicarlas al caso mexicano podría refinar la identificación sin necesidad de la cota numérica de elasticidad.

Modelo no lineal. Un VAR con cambio de régimen markoviano (MS-VAR) capturaría el cambio en la efectividad de la política monetaria entre el régimen de pre-inflación-target y el régimen actual. El paquete MSBVAR de R permite implementarlo sobre la misma base de datos.

Robustez al tipo de cambio. Replicar el ejercicio sustituyendo la serie SR15997 del Banxico por la del IFS (cuando esté disponible) permitiría aislar el efecto de la diferente cobertura de socios comerciales y cuantificar su contribución al residuo entre nuestra estimación y la del paper.

10.4 Cierre

Más allá de los hallazgos sustantivos, este ejercicio tiene valor metodológico independiente. Mostró que la elección entre estimadores estadísticamente equivalentes (en sus propiedades asintóticas óptimas, como MLE bajo correcta especificación) y estimadores robustos pero menos eficientes (como OLS+HAC) puede tener consecuencias sustanciales para los resultados estructurales cuando

dichos estimadores entran en el cálculo de objetos derivados —en este caso, la cota $\hat{\beta}_{\text{lower}}$ que filtra los modelos admisibles—. La replicación obliga a leer con cuidado no sólo qué hace un paper, sino *cómo* lo hace, y a desconfiar de las “mejoras” silenciosas que pueden romper la replicabilidad sin generar errores visibles. La memoria persistente de estos diagnósticos, documentada en este informe, busca evitar que un colaborador futuro repita el mismo proceso desde cero.

Repositorio de código y datos: C:/Users/carlo/.../varras/

Versión MATLAB: R2025b. *Versión R:* 4.5.0. *Versión Stata:* 17.

Scripts principales:

Code/0Proc_data.R – procesamiento de datos.

Code/0b_brecha_kalman.R – filtro de Kalman para producto.

Code/1DickeyFuller.R – pruebas de raíz unitaria.

Code/3SVAR_Mexico.do – diagnósticos VAR e IRFs Cholesky en Stata.

Code/SVAR_SignRestrictions.m – estimación SVAR con restricciones de signo.

Code/4Informe_replicacion.R – informe HTML de replicación.